

目 录

摘 要	1
Abstract	1
第 1 章 导论	2
1.1 研究背景与意义	2
1.2 国内外研究现状	3
1.2.1 基于传统方法的人脸表情识别方法	3
1.2.2 基于深度学习的人脸表情识别方法	5
第 2 章 基于深度学习的人脸表情识别基础理论	8
2.1 图像预处理理论	8
2.1.1 人脸检测与对齐	8
2.1.2 灰度化与直方图均衡化	8
2.1.3 数据增强策略	9
2.2 卷积神经网络基本原理	10
2.2.1 卷积层	10
2.2.2 激活层	10
2.2.3 池化层	11
2.2.4 全连接层	12
2.3 多尺度特征提取理论	12
2.3.1 多尺度卷积核并行	12
2.3.2 特征金字塔架构	13
2.3.3 空洞卷积	13
2.4 注意力机制理论	13
2.4.1 通道注意力机制	14
2.4.2 空间注意力机制	14
2.4.3 自注意力机制	15
第 3 章 基于多尺度卷积与全局注意力的人脸表情识别网络设计	16
3.1 网络整体架构概述	16
3.2 骨干特征提取网络设计	17
3.3 空洞空间多尺度金字塔模块	18

3.4 Transformer 编码块与全局注意力机制	20
第 4 章 实验结果与分析	25
4.1 实验环境	25
4.2 训练参数设置	25
4.3 消融实验分析	26
4.4 对比实验	27
4.5 混淆矩阵分析	29
4.6 可视化分析	30
第 5 章 结论	32
5.1 主要工作	32
5.2 不足与展望	32
参考文献	34
致谢	36

第 1 章 导论

1.1 研究背景与意义

面部肌肉所发生的细微运动会马上表现出中枢神经系统里面比较复杂的情感变化。让计算机具备识读面部情感的能力，也就是人脸表情识别 (Facial Expression Recognition, FER)，是推动计算智能向感知智能转变的重要环节，也是情感计算范畴内重要的研究内容^[1]。

20 世纪 70 年代，心理学家保罗·艾克曼依靠实证分析确定了人类六种基本面部表情，包括愤怒、厌恶、恐惧、快乐、悲伤和惊讶^[2]，并以此建立了面部动作编码系统 (Facial Action Coding System, FACS)^[3]。该系统把面部肌群的运动单元进行拆解，达到了对主观情感表露进行具象化几何测算和数值化标定的目的。该模式的形成使人类面部表情的规范化表征有了方法参照，也给计算机视觉领域建立自动化表情识别模型奠定了必要的学理基础和数理推演模式。

深度学习和机器视觉技术的持续进步，使人脸识别的判别准确度、运行稳定性得到很大提高。这些技术已经不局限于实验室环境中的受控分析，而是可以在医疗健康、辅助驾驶、情感交流等多种实际场景^[4]中稳定应用。

(1) 智能辅助医疗与心理干预在临床医疗环境中，老年患者会出现认知功能障碍，重症监护病房 ICU 内有言语功能受损患者，婴幼儿群体表达能力不完善，这些患者都把面部表情看作生理痛感和心理状态的唯一表现形式。形成非侵入式视觉感知方式，能够帮助计算机对病人进行全天候且连续性的情感追踪和痛感等级标定，为临床医生动态调整镇痛方案给出具体依据^[5]。

进行精神心理病症的早期筛检时，抑郁症、焦虑症和自闭症患者一般会有比较明显的情绪遮蔽表现。FER 技术可以捕捉瞬间发生且不受自主意识调控的局部微表情，并从这些微表情中提取出明显的病理表现，它把隐蔽的视觉信号转化为具有高信度的诊断参照数据，表现出比较明显的临床应用潜力^[6]。

(2) 智能驾驶辅助与人机共驾安全

在智能交通模式中，人脸表情识别技术是建立人机共驾主动安防模式的重要技术支撑。系统可以实时获取驾驶员面部特征，并且准确判断疲劳表现、醉酒迹象或者突然出现的生理异常^[7]，这些异常情况包括频繁眨眼、面部发红、肌肉僵硬等，系统随后会启动分层次的预警方式。

驾驶者情绪发生改变，路怒引发的激愤状态尤为突出，已经变成交通事故发

生的主要诱因。负面情绪会让驾驶行为变得冒进，并且增加超速和违规变道的风险。FER 技术可以先期发现驾驶者的情感偏斜，并且利用语音助手等交互端口来进行情绪纾解和介入，这样可以减少由心理诱因所引发的事故概率，进而保护交通参与者的生命权益。

（3）具身智能与情感交互进化

在如今的陪伴型机器人应用场景中，机器人大多是被动接受用户的指令，并通过基于文本的大语言模型输出对话。这种模式表面上打着个性化陪伴的旗帜，实际上缺乏智能化和主动性。而 FER 技术能赋予机器人以第一视角观察用户情绪的能力^[8]，比如察觉到用户处于沮丧的情绪，机器人会主动开启对话，给予安慰和鼓励。当聊天时用户表现出不满，机器人也能及时观察到并更换聊天话题。拥有了 FER 技术，陪伴机器人就不再是冷冰冰的文本输出器，而是可以察言观色的综合智能体。在孤独经济盛行、社会老龄化的背景下，推动拥有情绪感知能力的智能体发展具有深远的商业战略意义。

1.2 国内外研究现状

面部表情是人们情绪最直接表现方式，表情识别一直是计算机视觉研究热点问题，而且表情识别发展可以分为三个主要时期。

一开始，研究人员的主要任务是用人脸的关键位置，例如眼角、嘴角、眉弓等处标记出相应的点，然后根据这些点之间的欧氏距离或者角度以及移动方向表示面部肌肉的变化从而识别表情类型^[9]。

20 世纪 90 年代初，随着计算机技术的发展以及数字图像处理技术的进步，人脸表情识别取得了长足进展，研究者们不再局限于对面部位置进行分析，而是关注更加直观也更具有客观性的表情信息，利用手动设计的特征提取方法来提取人脸面部纹理特征，然后用浅层机器学习分类器来进行分类。

从 2014 年后，以卷积神经网络为代表深度学习方法，在人脸表情识别领域起到革命性影响，实现由手工设计特征到让机器自动学习特征重大飞跃，大大减少研究人员工作量以及消除人为因素带来的偏见。由于其可以自动从大量原始图像中学到高层次复杂特征而不需要人为指导，从而极大提高模型对真实世界鲁棒性并很好地解决前面两部分主要问题。

1.2.1 基于传统方法的人脸表情识别方法

20 世纪 70 年代，心理学家保罗·艾克曼创立的面部动作编码系统为表情的量化提供了理论基础。在这一时期，研究者主要通过人脸关键部位（如眼角、嘴

角、眉弓等)手动标注特征点,并利用这些关键点之间的欧氏距离、空间夹角或位移矢量来表征面部肌肉的宏观形变。




图 1.1 基于动作单元的面部几何特征标定模型^[9]

Fig. 1.1 Action unit-based facial geometric feature calibration model^[9]

如图 1-1 所示, Tian、Kanade 以及 Cohn 在论文 *Recognizing action units for facial expression analysis*^[9] 中提出了一种较为完善的面部部件特征提取方法。作者们通过对上下唇边界以及眼睑边缘等面部重要位置进行准确地标记并不断计算它们之间欧式距离以及角度的变化并与事先设定好的规则相比较从而判断出对应的表情。这种方法虽然可以解决一些问题但是它对精确的特征点要求很高,在实际情况中如果出现人脸朝向变化或者部分被遮挡时,几何跟踪就失败。而且仅仅依靠几何的方法只能检测出大块肌肉运动而不能反映由于肌肉挤压造成的小范围皮肤褶皱及纹理变化也无法考虑到不同人之间很大的面部骨骼区别。

为了解决纯粹基于几何方法进行微表情分析所面临的困境, FER 的研究需要有一个可以同时考虑面部纹理以及自动总结出边界的方法。而从上世纪 90 年代中期开始,伴随着统计学习理论的发展完善,人脸表情识别也进入了机器学习的时代。这时的人脸表情识别一般分为“人脸检测及对齐-手工特征提取-浅层分类器判断”。

在这个时期,研究人员关注的是如何利用手工构造的数学算子将一张复杂的面部图像映射到一个有区分能力的特征向量上,比较著名的特征提取方法有局部二值模式 (Local Binary Pattern, LBP)^[10]、方向梯度直方图 (Histogram of Oriented Gradients, HOG)^[11] 以及 Gabor 小波变换^[12]。LBP 用中心点与其周围像素值比较结果进行二进制编码,可以以较低的时间代价获得较好的对光照鲁棒性,但是由于它忽略了全局的信息因此对于复杂表情纹理无能为力; HOG 计算每个小块中的梯度方向直方图从而描述人脸的大致形状,但是当人脸有较大角度变化或者部分被遮挡的情况下就不如人意;而 Gabor 小波变换模拟人眼对于不同尺度以及不同方向的感受,可以提取非常细微的表情细节,但是由于它所带来的高维度以及高昂的时间代价使得它很难用于在线识别。

在大量高维手工特征被提取之后,它们被送入浅层机器学习方法中进行降维

以及判别学习。支持向量机支持向量机 (Support Vector Machine, SVM)^[13] 因其对高维小样本数据具有良好的泛化性能而在本部分中最为常用的一种分类工具。SVM 使用核技巧将非线性面部特征映射到高维空间之后寻找一个把各个情绪类别分开并且间隔最大的超平面。同时，主成分分析 (Principal Component Analysis, PCA)^[14] 用来去除特征空间中的冗余噪声从而得到主要的表情子空间；而 AdaBoost、随机森林等集成学习方法^[15] 则是结合许多较弱的分类器形成一个较强的分类器。此时，机器不需要研究人员给出固定的物理阈值，而是在大量的标注数据上反复训练后，在统计意义下自己学到不同面部表情之间的非线性关系。

为了直观呈现这些传统算法的特性与差异，下表对上述手工特征提取算子与分类算法的特点进行了系统对比：

表 1.1 传统面部表情识别常用算法特性对比
Table 1.1 Comparative analysis of traditional FER methods

类别	算法名称	核心逻辑与优势	局限性分析
特征提取	LBP	局部灰度对比编码，计算速度极快	忽略全局空间结构信息
	HOG	局部梯度方向统计，捕捉轮廓能力强	对图像旋转与遮挡鲁棒性差
	Gabor	多尺度多方向滤波，细节表征精细	特征维度极高，计算耗时较长
分类识别	SVM	最大化类别间距，小样本表现优异	对大规模数据训练效率较低
	AdaBoost	弱分类器加权集成，具备特征选择能力	极易受到离群点和噪声干扰

传统机器学习方法在受控的实验室数据集 (如光照均匀、姿态端正、面部无遮挡) 上取得了令人瞩目的识别精度。然而，这种方法有着不少局限，研究人员需要手工设计特征算子并定义哪些特征 (比如眉毛的位移、嘴角的弧度) 是有效的，这不仅增加了研究人员的工作量，还有较强的主观性，难以保证设计的特征是针对表情分类的最优解。

更重要的是手工提取特征方法对人脸表情数据集要求很高，一旦出现不均匀光照、极端的面部偏移角度，人工设计的底层特征便会遭到毁灭性破坏，进而导致分类器输出灾难性的误判。这种特性注定了手工提取特征方法只适用于实验室研究，无法真正应用于真实场景下。

1.2.2 基于深度学习的人脸表情识别方法

自 2012 年 Krizhevsky 等人提出的 AlexNet 在 ImageNet 挑战赛中取得突破性进展以来，人脸表情识别技术正式开启了从手工提取特征到自主学习特征的转变。早期的深度学习研究主要集中于如何通过增加网络深度来提升模型对特征的学习能力。

Simonyan 等人于 2014 年提出的 VGGNet^[16] 是其中的奠基之作，该网络通过连续堆叠多个 3×3 的小型卷积核代替传统的大尺寸卷积核，不仅在保持相同感受野的同时大幅提升了网络的非线性感知力，更证明了通过加深网络层数可以有效捕获面部皮肤细微的纹理和肌肉运动趋势。

然而，随着网络层数的进一步突破，研究者发现模型在训练过程中会出现严重的梯度消失和退化问题。针对这一瓶颈，何恺明等人于 2015 年提出了经典的残差网络 ResNet^[17]。ResNet 的核心贡献在于引入了残差学习框架，通过构建恒等映射的跳跃连接，使得模型只需学习输入与输出之间的残差项。这种设计极大降低了超深层网络优化的难度，成为了目前表情识别领域最为广泛应用的骨干架构。

虽然 ResNet 解决网络过深问题，但是面部表情是既有细微之处（例如眼角弯度）又有宏观部分（例如嘴张开程度）的复杂非线性信号，有很强尺度依赖性，一个尺度的感受野很难同时关注到多个尺度的信息。因此，Szegedy 等人提出的 Inception 系列网络^[18] 采用多分支卷积的方法来捕捉不同尺度的信息，在同一层使用不同的卷积核大小（比如 1×1 、 3×3 、 5×5 等），从而可以同时获得不同尺度的感受野下的信息。这种方法可以同时获取人脸的整体结构以及局部细节，大大提高了特征多样性。在此之上，Lin 等人在 2017 年提出了一种新的多尺度框架——特征金字塔网络^[19]，它使用一种自上而下的方式以及横向连接的方式，把深层网络中的高层次语义信息和浅层网络中的高分辨率几何信息结合起来。在 FER 上，这种多尺度结合的方式对于自然环境中的人脸大小的变化是有很大帮助的，在处理由于头部姿势倾斜或者远处拍摄造成的小尺寸的人脸照片上也有明显的优势。

但是，在自然场景下获取的数据一般包含很多无用的信息以及噪声，如额头部位纹理、不必要背景或者发饰等，在多尺度卷积中都会被同样处理，造成大量不必要的激活值，从而降低对表情真正有用部分的重要性。为了解决这个问题，在众多大量多尺度特征中选择正确有用的部分，学者们开始使用注意力机制。Hu 等人提出 SENet 通道注意力^[20]，利用压缩和激励的方式自适应改变不同特征通道的重要性，大大提高与表情相关重要通道；紧接着，Woo 等人提出的 CBAM 模块结合通道注意力和空间注意力^[21]，使网络自动关注眼睛、嘴巴、鼻子等富含情绪的位置并避开由口罩、墨镜或者阴影造成的不良影响。

传统的卷积操作虽然已经在多尺度的特征学习方面取得了较好的成果，但是对于跨区域特征之间的联系仍然有所欠缺。表情通常是面部不同部位协调运动的结果，例如开心是眉毛、眼睛以及嘴巴之间跨域配合。2020 年，Dosovitskiy 等人提出的 Vision Transformer (ViT)^[22] 打破了局部感受性的局限性。ViT 采用基于多

头自注意力的全局建模方式，将图片分割成小块然后串起来，在此基础之上就可以建立起整张脸上的联系。在表情识别上，ViT 被证实对于由大角度的姿态偏差造成的特征缺失有很强的自愈能力，它利用整个上下文来弥补侧面或者部分遮挡所丢失的意义。但是 Transformers 类的方法因为缺少卷积带来的归纳偏置，一般都需要大量的训练数据支持并且耗费大量资源，不能应用于工业级实时监控场景。

目前，人脸识别领域的一个最新发展就是对多尺度卷积以及注意力机制进行结合并对其改进。一般而言，使用多个子网络（例如空洞空间卷积池化金字塔或改进 Inception）进行特征扩张之后再串联一些注意力模块进行特征抽提是目前一个很有效的方案。这种方式可以兼顾多尺度带来的信息量丰富性还可以利用注意力机制解决特征冗余的问题。

此外，在此基础上为使网络学到更优特征以增强其类间区分能力，学者们提出了多种不同形式损失函数，例如中心损失（Center Loss）^[23]、三元组损失（Triplet Loss）^[24]、间隔相关损失（如 ArcFace）^[25] 等。它们都通过对特征空间内同类表情簇大小进行压缩与不同类表情之间距离扩大来提高模型鲁棒性和泛化能力，在诸如 AffectNet^[26] 和 RAF-DB^[27] 等具有很高难度真实世界数据库上均获得良好效果。但同时也存在一个问题，即如何让如此复杂的融合型网络更加轻量化并且能够在保证较高准确率的同时还能适用于具身智能机器人、疲劳驾驶监控以及智能医疗服务等边缘设备上快速推理计算，这也是目前亟需解决难题之一。

第 2 章 基于深度学习的人脸表情识别基础理论

本章主要介绍本文研究算法所涉及的相关理论基础。首先阐述针对人脸表情图像的预处理理论；随后详细介绍卷积神经网络 (Convolutional Neural Network, CNN) 的核心运算逻辑及其在特征提取中的优势；随后，针对表情识别中的尺度敏感性与全局关联性，分别介绍了多尺度特征提取理论、注意力机制以及视觉互感器 (Transformer) 的数学本质。

2.1 图像预处理理论

在人脸表情识别过程中，原始图像中存在大量与表情无关的背景噪声、光照差异以及头部的姿态倾斜等影响因素。而进行图像预处理可以提升输入质量，使网络学习到干净整洁的人脸部的表情特征。

2.1.1 人脸检测与对齐

人脸检测以及对齐是整个识别的第一步，一般使用 MTCNN 或者 Dlib 等人脸检测方法^[28] 获取人脸位置。而对齐则是根据检测出的关键点 (例如眼角、鼻尖、嘴角) 进行仿射变换使脸部处于同一水平位置上。这在物理上消除由于头部转动造成的几何畸变，让后续的特征提取层只关注表情变化。

2.1.2 灰度化与直方图均衡化

在人脸表情识别预处理阶段，灰度化是将含有色彩信息 RGB 三通道图像转换为单通道灰度图像以降低计算开销，在表情中，一般认为表情是由脸部肌肉运动造成纹理、阴影以及形状改变所表示，而颜色对于表情的意义不大，因此为了去除颜色影响又能尽可能多地保留亮度细节，一般使用加权平均进行灰度化^[29]，即考虑人眼对于红色 (R)、绿色 (G)、蓝色 (B) 三种基本颜色的感受不同，赋予它们不同权重，其灰度化公式为：

$$Gray = 0.299 \times R + 0.587 \times G + 0.114 \times B \quad (2-1)$$

利用这种方法，图像虽然保留其主要纹理信息，但是其数据维度由原来的三个通道变为一个通道，在计算上，这使得输入的数据量减少到原来的三分之一，从而大大减轻后续的深度卷积神经网络的压力，提高特征提取的速度。

进行灰度化之后，因为人脸表情的数据集 (例如 RAF-DB、FER2013) 中会有很

多在自然环境下拍摄的照片，在不同的光照条件下，会造成人脸面部细节失真，在此基础上需要对图像进行增强以使图像更加清晰突出主要部分，就需要用到直方图均衡化的方法。直方图均衡化的原理是利用一个非线性的变换，把原图像中灰度值比较集中的区域扩展到整个灰度范围内的直方图上，而这种变换是以累积概率密度作为依据来实现的，对于灰度等级为 r_k 的像素点，经过直方图均衡化变换后的新灰度等级 s_k 为：

$$s_k = T(r_k) = (L - 1) \sum_{j=0}^k p_r(r_j) = (L - 1) \sum_{j=0}^k \frac{n_j}{n} \quad (2-2)$$

其中， L 为图像的灰度级总数， n 为图像总像素数， n_j 为灰度级 r_j 的像素个数。通过该变换，图像的动态范围得到扩展，原本隐藏在暗部或亮部区域的面部细微皱纹、嘴角弧度等特征变得更加显著。

2.1.3 数据增强策略

在人脸表情识别研究过程中，公开标注的数据集大小往往不能满足超深神经网络的要求，在此情况下可利用数据增强的方法对现有的少量数据进行变换或者生成新的样本以增加数据量进而提高模型的泛化能力以及鲁棒性，数据增强主要分为几何变换、像素变换和高级数据增强方法。

几何变换主要是对原始图像进行随机水平翻转、小角度旋转、随机裁剪等操作，既模拟了实际拍摄过程中面部图像所存在的几何偏移，又增加了少量的数据量，在一定程度上使得卷积神经网络具有识别不同几何变换下图像的能力，有利于防止过拟合的发生。

像素变换是对图像中像素值进行统计上的变化，从而更接近实际情况中的非理想成像情况，在此基础上对图片加入高斯噪声或者椒盐噪声以及进行高斯模糊可以使照片看起来像摄像头传感器受到的影响以及由于运动造成的图片模糊；还可以通过对图片改变亮度、对比度、饱和度以及加上颜色抖动和平移直方图来解决由于过度照明而导致的过曝或者是暗部细节丢失的问题。

此外，为进一步提高模型对于复杂场景的理解程度，学者们提出了一系列较为先进的数据增强技术，例如 Mixup^[30]、Puzzle Mix^[31] 等。它们并不只在单张图像内部进行操作，而是从信息融合角度扩大训练集在流形上的覆盖范围。其中 Mixup 是通过两幅随机选取图片以及它们对应标签做凸线性组合，在特征空间产生带有混合含义的新样本，迫使网络在分类决策边缘处有较好的线性连续性，减少其对

误标数据的依赖；而 Puzzle Mix 更进一步地根据图像显著性（Saliency Information）来重新排列图像的部分以保留主要部分的同时使样本重组。这种基于显著性的高级增强手段不仅极大地增强了注意力机制对重要情感区域的关注力度而且从根上解决样本不平衡问题有助于开发出具有良好工业实用价值的大规模人脸表情识别系统提供大量优质数据支持。

2.2 卷积神经网络基本原理

卷积神经网络 CNN 是一种具有局部连接和权值共享的前馈神经网络^[32]，广泛应用于图像识别，音频处理等领域。一个典型的卷积神经网络通常由卷积层 (Convolutional Layer)、激活层 (Activation Layer)、池化层 (Pooling Layer) 以及全连接层 (Fully Connected Layer) 多层堆叠级联构成，各部分协同完成特征提取与分类任务。

2.2.1 卷积层

卷积层是 CNN 的核心组件，其主要功能是提取输入数据的特征。通过一组可学习的卷积核（Filter）在输入图像上进行滑动窗口运算，生成特征图（Feature Map）。其数学表达式如下：

$$y(i, j) = \sum_m \sum_n x(i + m, j + n) \cdot w(m, n) + b \quad (2-3)$$

其中， x 为输入特征图， w 为卷积核参数， b 为偏置项。卷积层具有两大核心特性：

- **局部感知：**每个神经元仅与输入层的一个局部区域相连，模拟了视觉皮层的局部敏感特性。
- **权值共享：**同一个卷积核在整个输入图像上共用参数，这在处理高维的面部图像时，极大程度地减少了待训练的权值数量。

2.2.2 激活层

由于卷积运算本质上是线性变换，而面部表情产生时的形变具有高度的非线性特征。激活层的作用是在网络中引入非线性映射，使得模型能够拟合复杂的函数关系。目前在人脸表情识别领域，常用的激活函数包括以下几种：

1. **ReLU：**线性整流函数^[33]是目前深度学习中最广泛使用的激活函数。其定义为：

$$f(x) = \max(0, x) \quad (2-4)$$

ReLU 的优势在于其在 $x > 0$ 区域的导数恒为 1，这有效缓解了深层网络中的梯度消失问题，并使得网络具有稀疏激活的特性。

2. **Leaky ReLU**: 针对 ReLU 在 $x < 0$ 区域梯度为 0 导致神经元坏死的问题，Leaky ReLU^[34] 引入了一个微小的负斜率 α :

$$f(x) = \begin{cases} x, & x > 0 \\ \alpha x, & x \leq 0 \end{cases} \quad (2-5)$$

这种改进确保了在负区间仍有梯度，有助于模型学习到面部图像中微弱的负相关特征。

3. **GELU**: GELU 是深度学习模型中广泛使用的激活函数之一^[35]，其结合了层归一化和激活的思想，通过高斯分布的累积分布函数来加权:

$$f(x) = x \cdot P(X \leq x) \approx 0.5x \left(1 + \tanh \left[\sqrt{2/\pi} (x + 0.044715x^3) \right] \right) \quad (2-6)$$

GELU 在非线性建模中引入了随机性，解决了传统激活函数神经元失活和非平滑等问题。

2.2.3 池化层

池化层通常紧随卷积层之后，池化层的作用是对卷积操作后的特征图进行统计处理 (包括最大化和平均化)。池化层能减少特征图的尺寸，降低后续卷积的计算量和参数量。

1. **最大池化**: 最大池化是表情识别中最常用的采样方式。它在预定义的滑动窗口内提取最大像素值作为输出。其数学表达为:

$$y_{i,j} = \max_{m,n \in \mathcal{R}} (x_{i+m,j+n}) \quad (2-7)$$

其中 $\mathcal{R}$ 为池化核覆盖的区域。最大池化能够提取图像中的显著性特征，同时抑制背景中的微小噪声。它赋予了模型一定的平移不变性，即关键表情特征在小范围内发生位移时，输出依然保持一致。

2. 平均池化: 平均池化通过计算滑动窗口内所有像素的平均值进行下采样:

$$y_{i,j} = \frac{1}{|\mathcal{R}|} \sum_{m,n \in \mathcal{R}} x_{i+m,j+n} \quad (2-8)$$

相比于最大池化, 平均池化能够更好地保留图像的全局背景信息和平滑特征, 常被用于网络末端的全局平均池化层, 将整个特征图压缩为一个全局特征向量, 从而有效防止模型对局部噪声产生过拟合。

2.2.4 全连接层

全连接层通常位于网络的最末端, 其中每个输出神经元都与上一层的神经元相连接, 通过线性变换和激活函数起到特征分类的作用。它负责将前面各层提取到的多维特征图展平为一维特征向量, 并将其映射到最终的类别标签空间。增加全连接的神经元数量能提升模型复杂程度, 但同时也会导致参数量变大, 计算开销变高, 在实际应用中, 需要使用正则化方法应对全连接层的过拟合。

2.3 多尺度特征提取理论

传统卷积神经网络在进行人脸表情识别任务时, 常常面对一个挑战: 表情信号的特征在空间尺度上跨越极大。一方面, 惊讶时的张嘴或是愤怒时的眉头紧锁, 这种宏观特征通常需要较大的感受野才能完整提取出来。另一方面, 很多微观特征比如微笑时的嘴角上扬则必须要依靠较小的感受野才能精准捕捉。

然而, 传统的卷积网络只有固定的卷积核尺寸, 在每一层级只能以统一的尺度对图像进行采样。而且卷积核尺寸大小也难以达到平衡, 如果过大, 虽然能提取面部整体结构特征, 但在不断下采样的过程中极易过滤掉微弱的局部特征; 而尺寸过小, 虽保住了局部特征, 却无法感受面部表情的宏观特征。如此, 引入多尺度特征提取机制显得尤为关键。该理论通过构建具有不同感受野大小的并行或串行分支, 让网络能够在同一个层级下, 同步感知宏观构型与微观细节, 从而有效弥补了单一尺度在特征时的信息缺失。

常见的多尺度特征提取方法可以根据其实现逻辑大致分为多尺度卷积核并行、特征金字塔架构以及空洞卷积架构三大类。以下是这些方法的详细理论介绍:

2.3.1 多尺度卷积核并行

多尺度卷积核并行方法是 Szegedy 等人在 GoogleNet 中提出的 Inception 模块首次使用^[18]。这个方法的基本思想是在同一层内并排放置若干大小不同的卷积核

(例如: 1×1 、 3×3 、 5×5 等), 对输入特征图进行卷积运算, 之后将各个分支的结果进行归一化合并到一起, 在一个前向传播过程中获取不同尺度的信息。同时为减少计算量, 在较大的卷积核之前增加一个 1×1 的卷积层对通道数进行缩减。此方法后来应用到许多 Inception 类型的模型上 (包括 v2、v3、v4)、Xception 和一些较轻量级的模型如 MobileNetV2。这种方法利用并行的思想可以让不同大小的卷积操作可以一起执行从而提高效率, 在大尺寸卷积带来的较大开销下则用一个 1×1 卷积来减少通道数而使参数仍然较少。

2.3.2 特征金字塔架构

为了解决目标检测中小目标检测精度低的问题, Lin 等人在 2017 年的 Feature Pyramid Network (FPN) 中正式提出了特征金字塔架构^[19]。卷积神经网络进行前向传播时, 卷积池化操作会逐渐将高分辨图片变为更为精炼的低分辨率特征图。而特征金字塔架构就利用了前向传播时产生的不同分辨率特征图, 将特征图按分辨率从大到小像金字塔结构自底向上排列, 然后通过一条自顶向下的路径对高层的低分辨率特征图进行上采样, 并通过横向连接对低分辨率和高分辨率特征图进行融合。该架构没有使用额外的卷积核增加参数量, 而是利用了卷积神经网络训练时产生的多分辨率特征图来作为多尺度特征提取的结果。

2.3.3 空洞卷积

在图像识别中, 传统的卷积神经网络使用大 stride 卷积提高感受野但是会严重降低特征图尺寸从而造成空间信息损失, 为了解决这个问题 Fisher Yu 和 Vladlen Koltun 在 2016 年提出空洞卷积^[36]。空洞卷积的基本思路是在普通的卷积核中的某些位置填充一定的空洞 (即置为 0) 从而使卷积核在不增加额外参数的情况下可以看到的范围更大并且可以通过改变膨胀率来改变感受野的大小。多个不同膨胀率空洞卷积可以并行组成一个空洞空间金字塔池化 (Atrous Spatial Pyramid Pooling, ASPP) 模块^[37], 这个模块在同一个特征图上并行使用多个具有不同膨胀率空洞卷积, 然后把它们的结果连接在一起以获取多种尺度的信息。

2.4 注意力机制理论

注意力机制的设计受到人眼工作机制启发而提出。人类在观察事物时总是会把注意力集中在主要部分而不是整个视野都注意均匀分布。如果把这个思想运用到机器学习上, 那么注意力机制就变成了一个很好的方法来合理分配计算资源, 在计算资源有限的情况下, 从大量特征信息中挑选最有利于完成任务的特征而忽略

无关紧要的部分。

从本质上看，注意力机制的基本思想是特征重加权，在深度神经网络中，得到的特征图有多个空间位置以及多个通道，在各个不同空间位置、不同通道上的特征对于最后的表情识别起到的作用是不一样的，例如嘴角、眼角等空间上的信息远远大于脸颊、额头等非重要部分的信息对表情的影响，因此，注意力机制就提出了一种可学习的专门模块来计算出每一种特征的重要性，然后利用这个重要性来对原来的特征图进行加权求和的操作，从而达到突出有用特征而忽略无用干扰的目的。

依据注意力机制所起作用不同，在当前研究中出现较多注意力结构可以分为三种类型，每种类型的注意力结构设计思想以及实现方式各有侧重，用于解决不同类型问题，接下来进行具体阐述。

2.4.1 通道注意力机制

通道注意力机制主要关注的是不同通道间的关系，从而突出有用的通道并抑制无用的通道。而在人脸表情识别问题上，每个通道所表示的内容是不一样的，例如一些通道代表肌肉纹理，另一些通道代表光照变化，还有一些通道代表背景噪声等，那么怎样选择表情相关的通道就是提高特征质量的一个重要方面。

在诸多通道注意力机制里，Squeeze and Excitation(SE)是最常用也是最经典一种^[20]，其设计简单有效，符合表情识别轻量化要求。即 SE 先用全局平均池化把二维空间特征降维成一维向量，目的是提取每一个通道整体特性而不是局部特性；之后利用两个全连接层建立非线性变换函数，让模型自己发现不同通道间联系，从而得到每一通道相应重要程度。

从表情识别的角度考虑，SE 模块的优势十分突出：它可以自动选取并且加强对于某种情绪判断最有帮助的特征通道，例如表示眼睛皱起（愤怒、悲伤）、嘴巴张开（快乐、惊讶）等通道，同时抑制对于表情无用的通道，如光照变化、背景纹理等通道。这样一种选择性的加强手段可以在特征上使表情得到更好的表示，降低不必要的内容给之后分类带来的影响，特别是在光线变化较大、背景杂乱的真实环境中。

2.4.2 空间注意力机制

不同于通道注意力，空间注意力旨在准确检测出图像中重要的部分所处的空间位置，在人脸识别任务上，人脸上表达情绪的部分一般为眼睛、嘴巴、鼻子等几个部位，而像头发、背景以及脸部遮挡物这样的部分并非有用信息，因此空间注意

力就是要使模型关注有用的信息，而不去管无用的信息。

空间注意力机制的设计思想较为一般，主要分为以下三个步骤^[21]：一是对特征图的各个通道分别进行最大池化以及平均池化操作，得到两个新的特征图，主要是为了获取每个通道上的全局上下文信息以帮助后续的空间位置判断；二是在上述获得的最大池化以及平均池化的特征图基础上进行拼接，结合两者优点提高空间位置的辨别能力；三是用一个小的卷积核进行特征融合以及降维操作得到一个大小为 $H \times W$ 的空间权重掩膜，然后将此掩膜与原特征图相乘就可以大大加强重要部分而减弱次要部分。

根据自然场景下表情识别所面临的问题，空间注意力机制具有良好的适用性，在实际使用中，由于人脸表情识别很容易受到面部遮挡或者头部姿态的影响，例如戴口罩只露出嘴巴或者戴墨镜只露出眼睛等情况下，如果模型不能准确定位到未被遮挡部分，则容易造成错误判断，但是空间注意力可以自动发现并且避开这些遮挡物，通过对未被遮挡部分加大其重要性来使模型在各种情况下都能检测出重要的面部肌肉活动，提高模型鲁棒性^[38]，这也是为什么空间注意力经常用于自然场景下表情识别的原因。

2.4.3 自注意力机制

随着表情识别研究逐渐走向高阶智能时代，传统的卷积操作已经暴露出其弊端：由于卷积操作具有局限性的局部感受野，在局部范围内只能观察到邻近像素点之间联系，而不能反映面部各个部位之间远距离的空间关系。但是实际上，一张人脸的表情是由许多部分协调完成的，例如眉开眼笑就需要眉毛、眼睛以及嘴巴共同作用，咬牙切齿也需要面部很多肌群一起工作，这些远距离协作关系是用传统的卷积不容易学到的，而自注意力机制正好可以解决这个问题。

自注意力机制是 ViT 的核心组件^[22]，其本质是通过计算特征序列中各个元素之间的两两关联性，实现全局范围内的特征建模，打破了局部感受野的限制。与传统卷积操作局部感知的逻辑不同，自注意力机制能够捕捉图像内任意两个像素点之间的关联关系，无论这两个像素点的距离有多远，都能建立有效的语义关联，这一特性非常适配人脸表情识别中多器官协同运动的需求。

在人脸表情识别中，自注意力机制的优势是能较好地建模面部各个部位之间的协同运动关系，在识别悲伤表情时，自注意力机制可以注意到双眉紧皱、嘴角下垂、眼睛微微闭上这些不同的地方所对应的表情信息，在整体上把握其含义而不是仅仅局限于某一处而导致错误判断。

第 3 章 基于多尺度卷积与全局注意力的人脸表情识别网络设计

针对真实自然场景下人脸表情尺度多变、局部遮挡及难以兼顾全局和局部特征等挑战，本章使用了一种混合架构，该网络使用空洞空间金字塔池化 ASPP 来提取多尺度特征信息，并引入了基于 Transformer 编码器中的多头自注意力机制 (Multi-Head Self-Attention, MHSA)，实现跨区域面部特征的全局交互与聚合。

3.1 网络整体架构概述

卷积神经网络 CNN 凭借其局部连接与权值共享的特性，在处理面部细微肌肉形变、皮肤褶皱等单个局部特征方面展现了卓越的感知能力。然而受限于 CNN 中固定的卷积核感受野大小，单纯的 CNN 架构在处理面部表情这种高度依赖跨区域特征融合 (比如眼角收缩和嘴角上扬) 的任务时，往往难以同时兼顾多个跨区域面部特征。针对这一种局限，本文引入了空洞空间金字塔池化和多头自注意力机制，即基于空洞金字塔池化和多头注意力机制 (Atrous Spatial Pyramid Pooling and Multi-Head Attention, ASPP-MHA) 的多尺度卷积神经网络。




图 3.1 ASPP-MHA 网络整体结构

Fig. 3.1 Overall architecture of the ASPP-MHA network

该网络计算过程是：首先使用预训练的 ResNet-50 作为主干网络利用其残差模块对人脸表情进行初步特征表示；然后将得到特征传入空洞空间金字塔池化 ASPP 中，使用不同扩张率的空洞卷积扩大感受野从而可以同时获得面部细粒度纹理以及粗粒度轮廓特征，然后再把它们融合之后拉成一维序列并且在最前面添加一个可学习全局分类标记 ([CLS] Token) 进入 Transformer 编码器里面，在那里用 MHSA

学习各个面部部分之间关系，最后从经过多个头自注意力之后 [CLS] 标记就是这张脸的表情摘要向量，再经过 BatchNorm 以及线性全连接层映射出最终 7 种表情分类结果。

3.2 骨干特征提取网络设计

在特征提取的初级阶段，本文选用 ResNet-50 作为骨干网络。传统的深层卷积网络在增加深度时，往往会遭遇退化问题：即随着网络层数的增加，训练集的准确率反而趋于饱和甚至下降，这并非由过拟合引起，而是深层网络难以进行恒等优化。而 ResNet 网络卓越的残差学习机制，通过引入快捷连接，将网络学习的目标由原始映射转变为残差映射，这对于捕获人脸表情中细微且复杂的非线性特征至关重要。




图 3.2 残差连接结构示意图^[17]

Fig. 3.2 Schematic diagram of the residual connection structure^[17]

如果没有快捷连接，每一层卷积都试图对这些复杂的背景信息进行非线性变换。随着层数加深，这种重复的重构会导致原始信号的冲淡甚至扭曲，即产生信息丢失。而残差连接将原始信息直接锚定到输出端。这确保了无论网络多深，最基础的面部结构信息都能实现零损耗传递，为后续特征提取提供了一个稳定的参照。

在 Deep Residual Learning for Image Recognition^[17] 中，作者提供了不同版本的 ResNet，以适应不同的性能需求和应用场景，本文选择了 ResNet-50 结构，相较于 ResNet-18 和 ResNet-34 结构，ResNet-50 的深度明显增加，可以尽可能提取出每张表情上的关键特征，而且 ResNet-50 的参数量和低深度 ResNet 结构处于同一数量级，不会造成计算瓶颈。

如图 3-3 所示，ResNet-50 的网络结构有五个部分组成。一个大小为 $224 \times 224 \times 3$ 的三通道输入图片，在进入网络后，先经过一个步长为 2 的 7×7 卷积层以及紧




图 3.3 ResNet-50 结构示意图
Fig. 3.3 Schematic diagram of the ResNet-50 structure

接着的一个 3×3 最大池化层，将原始图像快速缩小到 56×56 大小的同时也获得最初的 64 个特征通道。之后，便是四个主要部分串联而成的 Bottleneck 堆叠区域，在这四个 Bottleneck 堆叠区域内，都是由三种不同类型 Bottleneck 连接而成，分别是前面的 1×1 卷积（降维）、中间的 3×3 卷积（特征学习）以及最后的 1×1 卷积（升维）。而这样的两头宽、中间窄的方式不仅大大增强了网络对复杂性的表示能力而且也极大地减少了参数量。

在 Stage2 中，有三个瓶颈块保持 56×56 的大小并把通道数增加到 256。然后是 Stage3 部分有 4 个 bottleneck blocks，将特征图大小缩小一半变为 28×28 并且通道数量增加一倍为 512。接着是网络中最重的部分即 Stage4，有 6 个 bottleneck block 对特征图进行下采样使其变为 14×14 并且通道数量也增加一倍为 1024。最后 Stage5 包含三个瓶颈块将特征图固定为 7×7 以及最大 2048 维，在每个瓶颈块中都是先减少通道数提取重要特征然后再增加通道数的过程。最初的 ResNet-50 模型在 Stage5 之后连接一个平均池化及一个线性层完成分类任务，但是这里还需要对得到特征进行多尺度卷积融合的操作，因此要将经过 ResNet-50 得到大小为 $7 \times 7 \times 2048$ 的张量送入空洞空间金字塔池化 (ASPP)，以获得不同尺度的信息。

3.3 空洞空间多尺度金字塔模块

从骨干网络 ResNet-50 获取到的基本特征来看，该模型已经具有较好的特征表示能力，但是由于人在实际生活中存在较大的尺度变化以及不同表情的差异性特征分布于不同范围的空间区域，单个感受域的卷积对小范围内的细小皱纹如眼

角处和大范围内的整体动作如大笑等无法兼收并蓄。比如，观察眼角的小褶皱需要较小的感受域，而理解大笑时整个脸部以及嘴巴周围的肌肉运动就需要更大的感受域。为了解决这个问题，在骨干网络后面添加了空洞空间多尺度金字塔模块 ASPP，这个模块的主要作用是让网络可以在不同的尺度下同时查看人脸，进而更好地理解复杂的表情语义。

ASPP 模块能够实现不同尺度信息提取的原因是由于它所包含的基本单元——空洞卷积（Dilated Convolution）。一般情况下，普通的卷积操作中，卷积核中的元素在空间上是紧密相邻的，如果想扩大感受野，则一种方法就是加大卷积核大小或者用下采样的方式减少图像尺寸，但是这样会导致计算量大大增加或者是图像中的一些重要细节被抹除；而空洞卷积则是利用一个膨胀率（Dilation Rate），在卷积核相邻权重之间插入一定的数量的零值，在不增加额外参数以及计算复杂度的情况下，可以让卷积核能以跳跃的方式扫描更大的范围。




图 3.4 3x3 卷积与 3x3 空洞卷积对比

Fig. 3.4 Comparison between standard 3x3 convolution and 3x3 dilated convolution

图中左边是普通的 3×3 卷积，卷积核紧挨着输入图片，只从一个小块区域内取值然后与权重相乘求和得到输出-4，它的每一步的感受野就是这一个小块区域；右边是扩张率为 1 的空洞卷积，也是用同样的 9 个权重参数，但是相邻两个之间隔了一个像素点，这样就覆盖更大范围，即 5×5 大小的输入区域，进行同样的乘法以及加法操作之后得到输出 4。空洞卷积保留基本原理的同时，在处理像人脸识别这类需要同时关注大范围背景和小范围细节问题上非常有效率地获取更多全局信息而又不会忽略重要局部特征。

而在本文所提出的设计方案中，ASPP 使用四条路径来获取来自 ResNet-50 的尺寸为 $2048 \times 7 \times 7$ 的高维特征图。第一条支路使用普通的 1×1 卷积，用于保持最初的局部细节并且进行通道上的简单融合；第二、三条支路使用不同膨胀率即为 2 和 4 的 3×3 空洞卷积，其中这两个支路由于具有不同的空洞率可以分别关注到人脸较大范围内器官间的互动关系以及更大范围的表情轮廓特征；最后一条支路是使用全局平均池化操作，将整个特征图的所有内容汇总成一个总体的感受来反映整体的情绪基调。这四个支路各自完成自己的任务之后，得到的特征图的通道数都被降到 256 维，保证后续计算的一致性和效率。




图 3.5 ASPP 模块示意图

Fig. 3.5 Schematic diagram of the ASPP module

这种多分支设计有利于建立一种动态的感受野矩阵，在一定程度上复现人眼自下而上的视觉认知过程，在特征流动路径尽头，ASPP 模块将这四个有较大区别的特征图在通道方向上进行连接 (Concatenate)，得到一个有 1024 个通道数的特征张量，再通过一个 1×1 的融合卷积将其降维至 512 维，这样既可以去除不同尺度特征之间的重复内容，也可以利用非线性变换加强各尺度之间联系，最后经过 ASPP 提取出的信息既包括低层次卷积所检测到丰富细节，又有高层语义对于整个图像把握，从而给后面传入 Transformer 编码器做序列建模奠定坚实基础。

3.4 Transformer 编码块与全局注意力机制

尽管 ASPP 模块极大地丰富了多尺度特征，但卷积操作在本质上仍局限于局部感受野，难以建立跨面部区域（如左眼与右嘴角之间）的长距离依赖关系。为

此，本文在网络深层引入了标准 Transformer 编码块。

1. 序列化与 [CLS] 令牌融合 ASPP 模块输出的特征图尺寸为 $512 \times 7 \times 7$ 。在进入 Transformer 之前，首先将特征图在空间维度展平为长度为 49 的序列。为了汇聚整张图像的全局信息，本文引入了一个额外定义的可学习向量，即分类令牌 ([CLS] Token)，其维度与局部特征一致。拼接后的序列长度变为 50，作为多头自注意力机制的输入：

$$Z_0 = [X_{cls} \parallel X_1 \parallel X_2 \parallel \cdots \parallel X_{49}] \quad (3-1)$$

2. 多头自注意力机制

多头自注意力机制的数学推导是一个严密的张量变换过程，其核心在于将原始特征映射至多个独立的子空间中进行全局相关性建模。




图 3.6 多头注意力结构图

Fig. 3.6 Structure diagram of multi-head attention

对于维度为 $X \in \mathbb{R}^{50 \times 512}$ 的输入序列，在这一步骤当中，由于要进行 8 个头并行操作，因此网络定义三个可训练参数矩阵 $W^Q, W^K, W^V \in \mathbb{R}^{512 \times 512}$ 。而对于每个单独的注意力头 $i \in \{1, \dots, 8\}$ ，它所对应的小型化投影矩阵分别是 $W_i^Q, W_i^K, W_i^V \in \mathbb{R}^{512 \times 64}$ ，这里特征尺寸大小 $d_k = 64$ 即原维数 512 除以 8 得到的结果。然后用这些矩阵去乘以输入 X 得到这个头对应的查询矩阵 Q_i 、键矩阵 K_i 和值矩阵 V_i ：

$$Q_i = XW_i^Q \quad (3-2)$$

$$K_i = XW_i^K \quad (3-3)$$

$$V_i = XV_i^W \quad (3-4)$$

此时，经过投影之后的矩阵维数均为 $\mathbb{R}^{50 \times 64}$ 。

在得到每个多头的 Q 、 K 、 V 后，进入到缩放点积注意力部分，在这里用每个查询向量与每个键向量之间相似性确定相对重要性。首先，计算 Q_i 和 K_i 的转置矩阵相乘得到描述整个序列两两之间关系的一个分数矩阵 $Q_i K_i^T \in \mathbb{R}^{50 \times 50}$ 。由于在高维情况下点积可能会很大，从而使 **Softmax** 函数在梯度饱和区，所以要除以一个缩放系数 $\frac{1}{\sqrt{d_k}} = \frac{1}{\sqrt{64}} = \frac{1}{8}$ 。然后，在每一行上应用 **Softmax** 函数进行归一化，得到注意力权重矩阵。之后，将这个权重矩阵乘以对应的值矩阵 V_i ，完成对特征加权求和操作。完整的单头计算如下：

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i) = \text{softmax}\left(\frac{Q_i K_i^T}{\sqrt{d_k}}\right) V_i \quad (3-5)$$

得到的结果是 $\text{head}_i \in \mathbb{R}^{50 \times 64}$ 不再是简单的局部特征，而是一个结合了整个脸部 50 个空间位置周围的信息的表示形式。这个方法让每一个空间上的 **token** 都要找到并且吸收整张图片中最相关的部分的信息。

最后，计算管线进入拼接以及最终线性投影的过程，在经过 8 个注意头上各自对应的小空间中完成特征学习之后，系统进行一次拼接操作 (**Concatenate**)，把 8 个大小为 $\mathbb{R}^{50 \times 64}$ 的头输出连接起来。这样得到的新张量 $\text{Concat}(\text{head}_1, \dots, \text{head}_8)$ 又回到原来的 $\mathbb{R}^{50 \times 512}$ 形状上，并且汇总了来自 8 种不同角度的所有内容。为使这些不同的小空间的信息能够充分融合并且进一步提炼出更有价值的特点，模型设计了一个全局输出投影矩阵 $W^O \in \mathbb{R}^{512 \times 512}$ ，最后的结果用以下公式表示：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_8) W^O \quad (3-6)$$

通过这样一层线性变换，之前在 8 个不同的头里面得到的零散的特征都映射到了同一个特征空间之中，去除了由于多头带来的重复。最后得到一个大小为 50×512 的矩阵，在保证与输入相同大小的基础上实现了从局部的空间注意力到全局依赖的大飞跃。

3. 前馈神经网络

在 Transformer 架构中，前馈神经网络 (Feed Forward Network, FFN) 位于多头自注意力层之后，起到一种特征深度精炼作用，在自注意力学习序列内部不同位置之间相互交流、建立起整体联系基础上，FFN 对每个位置的特征分别做一次非线性变化以及语义刻画，这样可以让模型不仅能够形成整个脸部的关系，而且也可以针对每个小部分的位置提取较深的知识。而在人脸表情识别上，由于有 FFN 的存在，所以网络可以将自注意力得到跨区域的联系映射到更高层次的表情表示当中，进而提升对于复杂的、微妙的脸部变形的描述能力。




图 3.7 FFN 网络结构图

Fig. 3.7 Structure diagram of the feed-forward network (FFN)

如图 3-7 展示的具体结构，FFN 采用了先升维再降维的瓶颈式设计，以实现高效的非线性映射。输入特征向量 Z'_l 是由 MHSA 的输出特征向量先与 MHSA 的输入特征向量进行残差连接，然后进行层归一化处理得到的。如以下公式，其中 Z_{l-1} 表示进入 MHSA 前的输入特征向量。

$$Z'_l = LayerNorm(MHSA(Z_{l-1}) + Z_{l-1}) \quad (3-7)$$

Z'_l 首先进入特征扩张层 (Feature Expansion)，通过线性变换将其投影至 2048 维的高维空间，这一步的物理意义在于通过空间扩张提供更大的特征容量。随后，高维特征通过 GELU 激活函数进行非线性处理。相比于传统的 ReLU，GELU 能够提供更平滑的梯度流，这使得模型在处理如微弱皮肤褶皱等极细微的情感信号时，能够保持更好的敏感度，避免特征在深层传递中丢失。

在完成高维空间的非线性提取后，特征进入特征精炼层 (Feature Refinement)，

将维度从 2048 重新压缩回 512。这一过程旨在剔除特征冗余，仅保留对表情分类最具判别性的核心信息。为了确保深层网络的训练稳定性，该模块引入了残差加法 (Add) 与层归一化 (Layer Normalization) 机制。残差加法将 FFN 处理后的增量信息与输入端的原始信息直接相加，确保了基础面部结构的完整性，有效缓解了深层网络的退化问题。最后的层归一化则对融合后的数据分布进行标准化，消除了数值波动，确保输出特征 Z_l 具备高度的鲁棒性。这种结构组合使得 FFN 能够以极高的效率完成特征的非线性重构，为最终的情感预测奠定了坚实的特征基础。最后输出特征向量 Z_l 可用公式表示为：

$$Z_l = \text{LayerNorm}(W_2 \cdot \text{GELU}(W_1 \cdot Z'_l) + Z'_l) \quad (3-8)$$

其中，相关参数定义如下：

- $W_1 \in \mathbb{R}^{512 \times 2048}$ 与 b_1 ：对应 **Feature Expansion** 层，通过线性映射将特征空间扩张 4 倍，旨在挖掘更深层次的非线性表情关联。
- $W_2 \in \mathbb{R}^{2048 \times 512}$ 与 b_2 ：对应 **Feature Refinement** 层，负责将高维特征精炼并投影回原始维度，以实现特征的降维压缩。
- **GELU**：高斯误差线性单元激活函数，用于引入非线性特性并保持梯度的平滑性。

第4章 实验结果与分析

4.1 实验环境

为了全面且公平地评估本文提出的多尺度注意力融合模型的有效性，所有的模型训练、验证与测试流程均在统一的硬件平台和软件环境下进行。

在硬件配置方面，本实验平台搭载了 AMD Ryzen 9 9955HX 高性能处理器，并配备了 16GB 高频 DDR5 内存，以保障数据预处理和加载过程的吞吐量。模型训练的核心算力由 NVIDIA GeForce RTX 5060 独立显卡提供，其自带的 8GB 显存能够有效支撑大批量图像数据的并行计算需求。

在软件环境方面，实验基于 64 位 Windows 11 操作系统展开。算法的底层逻辑采用 Python 3.9.25 进行编写，并依托目前学术界广泛使用的 PyTorch 2.8.0 深度学习框架完成了网络图的搭建、前向传播与反向梯度的计算。此外，为了最大化发挥底层 GPU 的张量运算性能，实验调用了 CUDA 12.8 以及 cuDNN 9.1.0 深度学习加速库。详细的软硬件配置清单如表 4.1 所示。

表 4.1 实验环境配置表
Table 4.1 Experimental environment configuration table

配置项目	具体参数
操作系统	Windows 11 (64-bit)
CPU	AMD Ryzen 9 9955HX 16-Core Processor @ 2.50 GHz
GPU	NVIDIA GeForce RTX 5060 Laptop (8GB)
内存	16GB DDR5
加速环境	CUDA 12.8, cuDNN 9.1.0
编程语言	Python 3.9.25
深度学习框架	PyTorch 2.8.0

4.2 训练参数设置

在模型训练过程中，因 RAF-DB 和 FER2013 数据集在图像尺寸大小、样本数量以及标签噪声比例等方面不同，本文在这两个数据集上使用不同的超参数配置以及训练方法。对于网络结构的变化，本文均采用差异化的学习率：即 ResNet50 主干网络的学习率设置为全局学习率 η 的 10%，而增加的 ASPP 模块、MHSA 模块以及全连接层则以完整 η 的速度进行参数更新，以便更好地让浅层已经学到的特征尽快被优化。

在 RAF-DB 数据集上，实验批处理大小 (Batch Size) 为 48。优化器是带有动量

的随机梯度下降 (SGD) 优化方法, 动量因子为 0.9, 权重衰减为 1×10^{-4} 。初始全局学习率 η 设置为 0.1。同时采用步降法进行学习率衰减, 在每 10 个 Epoch 后将学习率降低到原来的十分之一, 一共进行 40 个 Epoch。

对于数据增强, 在每个输入图像被调整到 224×224 大小后, 进行随机左右翻转以及随机擦除 (Random Erasing, 擦除比例为 0.02 到 0.25) 操作。另外, 为了缓解训练过程的过拟合现象, 本文加入了 Mixup^[39] 的数据增强方法 (插值系数 $\alpha = 0.2$), 即从数据集中随机选取两个样本及其对应的独热编码标签, 然后将它们以一定的比例混合得到新的训练样本以及其对应的软标签交叉熵损失。




图 4.1 Mixup 效果示意图
Fig. 4.1 Visualization of the Mixup effect

FER2013 数据集中图像尺寸很小 (48×48) 并且有很多错误标注的样本, 所以在其上使用了更加强烈的数据增强以及正则化方法。批量大小设为 64, 优化器也是 SGD, 但是由于大而复杂的网络容易导致对低质量有噪声数据过度拟合的问题, 在这里加大了权重衰减系数到 5×10^{-4} 。另外, 初始学习率降低到 $\eta = 0.01$ 并且采用余弦退火的学习率退火方式 (CosineAnnealingLR) 使得网络可以在 50 轮之后用一个小的学习率稳定地收敛到一个局部极小值。

4.3 消融实验分析

为了进一步研究本文所提出的多尺度空洞空间金字塔池化 (ASPP) 及多头自注意力机制 (MHSA) 对于整个面部表情识别的影响, 在 RAF-DB 数据集上进行了一系列详尽的消融实验。

实验以 ResNet-50 作为基础网络 (Baseline), 逐步增加一个特征提取模块进行比较不同结构对模型性能影响。所有消融实验均使用相同的超参数设置以及数据增强方法, 以保证公平性。消融实验的结果见下表。

表 4.2 在 RAF-DB 数据集上的消融实验结果
Table 4.2 Ablation study results on the RAF-DB dataset

Baseline	ASPP	MHSA	准确率 (%)
✓	×	×	86.18
✓	✓	×	88.92
✓	✓	✓	89.50

这里的准确率，是指模型预测正确的样本数占测试集所有样本总数的比例。当采用 ResNet-50 作为 Baseline 时，在 RAF-DB 测试集中得到的准确率是 86.18%。尽管深层残差网络具有较好的局部特征感知能力，但是由于其每层的卷积核感受野大小是一致的，所以不能很好地同时关注到人脸的小细节 (例如眼角皱纹) 以及大的结构 (例如嘴巴张开)。

在 Baseline 上加入 ASPP 后，模型准确率得到很大提高，达到 88.92%，相比于 Baseline 提高 2.74%，这说明多尺度特征融合对于人脸表情识别是非常重要的。ASPP 使用不同的膨胀率的空洞卷积，在不增加过多参数的前提下，得到具有多种感受野的特征金字塔，从而让网络可以同时获得细微的表情变化以及整体的脸部形状信息，大大提高了模型对于各种大小的表情动作的检测效果。

最后加入了基于 Transformer 编码器的多头自注意力 (MHSA)，形成了 ASPP-MHA 结构，这时模型准确率达到 89.50%，比之前提高了 0.58%。这说明虽然 ASPP 提供丰富多尺度信息，但是由于卷积操作本身是局部性，不能直接捕捉到人脸部位之间长距离联系。“紧锁双眉”和“下垂嘴角”，这些远距离特征之间深层次关联只能由 MHSA 计算出它们之间相似度来实现，这样一种全局视角特征再加权方式使得模型更像人一样理解表情，因此得到更好效果。

4.4 对比实验

在本节中，我们将所提出的 ASPP-MHA 算法与当前主流的人脸表情识别方法进行了定量对比。实验分别在 RAF-DB 数据集上展开。

表 4.3 展示了 ASPP-MHA 算法在 RAF-DB 数据集上的表现。由数据可见，ASPP-MHA 算法取得了 89.50% 的准确率，全面超越了参与对比的现有主流方法。相比于经典的 ResNet 基准以及近期的 FerNeXt 等算法，其识别精度得到了显著提升。这表明通过引入空洞空间金字塔卷积架构，模型能够更敏锐地捕捉到野外复杂环境下脸部肌肉细微的纹理变化。

FER2013 数据集包含大量的低分辨率图片 (48×48 像素大小) 以及大量的错

表 4.3 RAF-DB 数据集性能对比

Table 4.3 Performance comparison on RAF-DB dataset

方法	时间	准确率
Baseline(ResNet-50)	2016	86.28%
SCN ^[40]	2020	87.03%
Ad-Corre ^[41]	2022	86.96%
FerNeXt ^[42]	2023	88.56%
TransFER ^[43]	2021	90.91%
ASPP-MHA(Ours)	2026	89.50%

误标注或者被遮挡严重的样本，在此基础上我们对模型鲁棒性进行测试，在此数据集中进行比较，如表 4.4 所示。

表 4.4 FER2013 数据集性能对比

Table 4.4 Performance comparison on FER2013 dataset

方法	时间	准确率
Deep-Emotion ^[44]	2021	70.02%
CNN-SVM ^[45]	2013	71.16%
Ad-Corre ^[41]	2022	72.03%
RMN ^[46]	2020	74.14%
ASPP-MHA (Ours)	2026	72.43%

从表 4.4 可以观察到，在非常具有挑战性的 FER2013 数据集上，所提出的 ASPP-MHA 方法仍然获得 72.43% 的测试精度。这远远优于使用空间注意力模块的方法如 Deep-Emotion 等 (70.02%)，同时也大大高于基于传统的浅层 CNN+SVM 的经典基线方法 (71.16%)。由此可见，我们提出的多头自注意力模块 (MHSA) 对于处理低分辨率噪声是有效的，它可以利用全局上下文关系来补充由于低分辨率导致的局部特征不清楚或者缺失问题。

此外，本文也比较目前在该数据集取得最优结果的一些方法，例如区域注意力网络 (RAN, 73.23%)、残差掩码网络 (RMN, 73.28%)。RMN 等网络使用 7 个卷积神经网络进行堆叠融合 (Ensemble)，而 RAN 模型在预处理中添加一个人脸特征点裁剪操作。相反，我们提出的 ASPP-MHA 使用一个模型完成从输入到输出的过程，在无须添加额外几何信息以及无需过多计算量的情况下，仍能达到很高的准确率，具有较好的模型复杂性和分类效果之间的折中。

4.5 混淆矩阵分析

为了更清晰、更详细地对比本文提出的 ASPP-MHA 模型在不同情感类别中的识别效果，以及探讨模型在实际复杂场景与严苛数据分布下所面临的挑战，我们分别绘制了模型在 FER2013 和 RAF-DB 数据集测试集上的归一化混淆矩阵，如图 4.2 所示。在这些归一化的混淆矩阵中，主对角线上的数值代表模型对该表情的识别正确率 (某类表情被正确识别的样本数，占该类表情全部真实样本总数的比值，即单类准确率)，而非对角线上的数值则反映了该类别被错误划分至其他类别的概率。




图 4.2 RAF-DB 和 FER2013 数据集混淆矩阵

Fig. 4.2 Confusion matrix on RAF-DB and FER2013 datasets

从两个矩阵的主对角线可以看出，ASPP-MHA 对大多数基本表情都有很好的区分能力，在“快乐 (Happy)”这个类别中，在 FER2013 和 RAF-DB 上的单类准确率分别达到了 88% 和 97%，因为“快乐”的表情一般都会有明显的嘴角上扬以及颧骨突出等具有强烈特点的表情，而且在真实世界的样本中也比较多，所以这个模型很容易把它们和其他的表情区分开来。“惊讶 (Surprise)”、“中性 (Neutral)”、“悲伤 (Sadness)”也都具有很高的单类准确率，说明本文使用的多尺度空洞空间金字塔模块与多头自注意力机制，可以更好地学习不同尺度下的面部细节并忽略复杂的背景信息，在很大程度上保证主流的表情识别准确性。

但是观察非对角线部分可以看出，在“恐惧 (Fear)、厌恶 (Disgust)”以及 FER2013 中的“愤怒 (Angry)”等负面情绪识别上存在困难。本文分析后认为造成这种情况主要有两点原因：

第一，由于面部肌肉群的动作相互关联造成很高的视觉相似度，在 RAF-DB

中约有 16% 的“恐惧”样本被错误地分类成“惊讶”，因为这两者都会引起眼睛张开、眉毛上扬以及张嘴等非常相似的整体面部形态；另外，“厌恶”约有 8% 和 7% 分别被误认为是“愤怒”和“悲伤”，主要是因为它们都会出现皱眉（眉间聚集）和嘴唇紧绷的情况。这些微小的局部特征重叠在低分辨率 FER2013(48×48) 下被进一步放大，在这个数据集中约有 23% 的“恐惧”被错分到“悲伤”，同时也有 16% 的“愤怒”被误归类为“悲伤”。虽然多尺度结构学到大量的空间信息，但是在很低的分辨率或者表情幅度较小的情况下，特征空间的边界仍然会有重叠。

第二，数据不平衡以及底层标签噪声使得少数类特征难以被良好建模，在 RAF-DB 数据集上，“恐惧”、“厌恶”是两类极小量级的数据，在整个网络进行全局自注意力映射的过程中很难完整地建模出这两类的所有特征流形，在遇到一些特征较弱的“厌恶”的时候，很容易就把它们压缩到数量众多的多数类当中（大约有 9% 左右的“厌恶”被很自然地归为“中性”）。而在 FER2013 数据集中，由于数据类别不平衡的原因外，本身就有很高的误标率，这也是造成它负面表情单类准确率较低的一个重要原因。

综上所述可知，混淆矩阵结果说明 ASPP-MHA 方法可以很好地应用于跨数据集的表情识别任务并且具有较好的鲁棒性，但是该模型对于高相似度的小样本表情识别易造成误判。

4.6 可视化分析

为了更好地了解模型在特征提取过程中所起的作用，同时证明了本文所提出的 ASPP-MHA 在处理复杂的人脸表情上是有效的，在这一部分利用 Grad-CAM(Gradient-weighted Class Activation Mapping) 来观察网络内部的特征图。Grad-CAM 是通过目标类别的导数与最后一个卷积层的特征图进行点乘得到一个热力图，该图中的红色部分是模型在判断过程中重视的部分，蓝色部分则是模型忽略的部分。

本文从 RAF-DB 测试集中挑选出三个有代表性的较为复杂的样本进行比较，Baseline 模型 (ResNet-50) 以及本文 ASPCT-MHA 模型注意力热力图如图 4.3 所示。

从图中可以看出，ASPP-MHA 模型在特征定位准确性以及鲁棒性方面都明显优于 Baseline 模型。这主要是因为：

首先，如图 4.3 第一行所示，Baseline 模型热力图存在明显特征涣散情况，其热点分布不仅局限在脸部中部，还蔓延到前额以及发际线附近，说明传统的 CNN 容易受到高对比度无关纹理干扰（例如头发），而 ASPP-MHA 模型很好地排除这些背景噪声，准确并且对称地集中在小女孩双眸及其周围的眼睑肌肉上，具有良




图 4.3 Grad-CAM 热力图对比分析
Fig. 4.3 Comparative analysis of Grad-CAM heatmaps

好的特征提取能力。

其次,如图 4.3 第二行所示,对于非常夸张的表情(比如恐惧或者惊讶),**Baseline** 模型关注点只集中在鼻子上方以及上脸颊附近很小一片地方,但是并没有注意到同样能够表达出强烈情绪的脸部下方区域。但是 **ASPP-MHA** 模型对“瞪大的双眼”以及“张开的嘴巴”这两个相隔很远并且互不影响的两个部分都有很强的激活反应。这个结果说明我们的多头自注意力确实克服了传统的卷积层只能看到局部信息的问题,在人脸的不同部位之间建立起一种远距离的整体联系。

最后,如图 4.3 第三行所示,当样本有一定程度的姿态变化并且表情比较含蓄(例如悲伤或者厌恶)的情况下,**Baseline** 模型的注意力集中在右侧脸颊以及阴影处。但是相比之下,**ASPP-MHA** 模型不但注意到了眼睛部位,而且注意到“嘴角下垂”,这是导致悲伤或者厌恶的原因。这是因为空洞空间金字塔卷积提供了不同的尺度的感受野,在获取大范围的信息的同时也不会忽略掉一些重要的细小的变化。

因此,由上述分析可知,可视化结果证明了 **ASPP-MHA** 模型的有效性。它能够像人眼一样关注人脸主要部位,同时利用多尺度及全局注意力分离复杂面部动作之间的联系从而提高模型对真实世界中图像分类准确性。

第 5 章 结论

本文针对真实自然场景中的人脸表情识别问题所面临表情尺度变化较大、部分遮挡以及不同地域间特征难以对应的问题，在研究深度学习应用于情感分析的基础上，提出一种利用空洞金字塔池化和多头注意力的方法进行人脸识别的表情识别方法。以下是本文的主要工作及不足。

5.1 主要工作

本文构建了一个基于多尺度空洞卷积的特征提取框架。由于传统的单尺度感受野不能同时关注到细微处的变化以及整体轮廓的变化，在此本文使用一个 ResNet-50 作为主干网络来提取基本特征，在此基础上串联了一个空洞的空间金字塔池化层 (ASPP)。利用多个不同的空洞卷积来进行并行操作，在保证较少运算量的情况下同时获得细粒度的面部肌肉变化以及粗粒度的脸部形状信息从而提高网络对于多种尺度的表情信息进行识别的能力。

由于传统的卷积不能很好地处理面部远端部位间相互作用问题，本文在网络中间层加入了多头自注意力机制 (MHSA)。它可以克服局部的感受野大小的约束，在眼-口-鼻等面部不同位置器官之间建立一种远距离的情感联系，在表达较为复杂情绪上也有所提高。

本文在极具挑战真实野外数据集 RAF-DB 和 FER2013 中进行模型测试, ASPP-MHA 分别获得 89.50% 和 72.43% 准确率, 远超传统经典模型 ResNet。为了验证模块的有效性, 本文设计了消融实验, 结果显示在基准模型 ResNet-50 加上 ASPP 和 MHSA, 准确率分别提升了 2.74% 和 0.58%。而且, 本文还设计了 Grad-CAM 可视化分析, 相比容易受到头发、背景等无关纹理干扰的普通网络, 本文所提方法可以有效去除环境噪声, 使关注点集中在主要表情部位上, 具有很好的鲁棒性。

5.2 不足与展望

虽然本文所提的 ASPP-MHA 模型整体上具有良好的表现, 但是由于客观因素以及目前的技术限制, 在研究中还存在不足之处需要在未来工作中进行更深入的研究与改进。

由于自然场景数据集中类别严重失衡 (例如, “快乐” 样本众多, “厌恶”, “恐惧” 等少量) 以及少数类面部表情之间细微差别较小导致模型对这类样本区分度不足, 在此基础上进行训练得到的结果仍然不能较好解决此问题, 可以尝试使用根

据数据分布变化调整权重的学习率 (如 Focal Loss) 或者更复杂的生成方法来改善这个问题。

加入 ASPP 以及 Transformer 模块虽然极大地提高准确率，但是也使得整个模型规模增大，对于计算资源有限的边缘设备而言是极大的负担，在以后的研究中可以尝试进行网络裁剪、权重量化以及知识蒸馏等方法来降低模型大小，以便使其能够在像具身智能机器人、辅助驾驶监控等终端设备上快速推理。

参考文献:

- [1] Pantic, M., & Rothkrantz, L. J. (2000). Automatic analysis of facial expressions: The state of the art. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 22(12), 1424-1445.
- [2] Ekman, P., & Friesen, W. V. (1971). Constants across cultures in the face and emotion. *Journal of Personality and Social Psychology*. 17(2), 124-129.
- [3] Ekman, P., & Friesen, W. V. (1978). Facial action coding system: A technique for the measurement of facial movement. *Journal of Nonverbal Behavior*. 3(1), 11-24.
- [4] 曾接贤, 郑伟. 基于深度学习的人脸表情识别方法综述 [J]. 计算机工程与应用, 2021, 57(11): 44-55.
- [5] 李勇, 王健, 等. 基于计算机视觉的面部疼痛表情识别研究进展 [J]. 生物医学工程学杂志, 2019, 36(4): 694-700.
- [6] 黄晔焯, 王素玉, 等. 面部微表情识别技术研究进展 [J]. 自动化学报, 2021, 47(11): 2503-2520.
- [7] 李文书, 陈晓宇, 等. 基于面部表情与特征状态的疲劳驾驶检测 [J]. 汽车工程, 2022, 44(5): 782-790.
- [8] 吴文峻, 陈益强, 等. 基于人脸表情的情感陪伴机器人交互系统 [J]. 机器人, 2018, 40(2): 211-220.
- [9] Tian, Y., Kanade, T., & Cohn, J. F. (2001). Recognizing action units for facial expression analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 23(2), 97-115.
- [10] Ojala, T., Pietikainen, M., & Harwood, D. (1996). A comparative study of texture measures with classification based on featured distributions. *Pattern Recognition*. 29(1), 51-59.
- [11] Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2005(1), 886-893.
- [12] Daugman, J. G. (1988). Complete discrete 2-D Gabor transforms by neural networks for image analysis and compression. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 36(7), 1169-1179.
- [13] 丁世飞, 齐建鹏, 等. 支持向量机理论与算法研究综述 [J]. 电子科技大学学报, 2011, 40(1): 2-10.
- [14] Turk, M., & Pentland, A. (1991). Eigenfaces for recognition. *Journal of Cognitive Neuroscience*. 3(1), 71-86.
- [15] 李旭, 侯青, 等. 基于 AdaBoost 和局部二值模式的人脸表情识别 [J]. 计算机应用研究, 2012, 29(10): 3971-3973.
- [16] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv. 1409.1556*, 1-14.
- [17] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016(1), 770-778.
- [18] Szegedy, C., Liu, W., Jia, Y., et al. (2015). Going deeper with convolutions. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015(1), 1-9.
- [19] Lin, T. Y., Dollár, P., Girshick, R., et al. (2017). Feature pyramid networks for object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017(1), 2117-2125.
- [20] Hu, J., Shen, L., Albanie, S., et al. (2020). Squeeze-and-excitation networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 42(8), 2011-2023.
- [21] Woo, S., Park, J., Lee, J. Y., et al. (2018). CBAM: Convolutional block attention module. *Proceedings of the European Conference on Computer Vision (ECCV)*. 2018(1), 3-19.
- [22] Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR)*. 2021(1), 1-34.
- [23] Wen, Y., Zhang, K., Li, Z., et al. (2016). A discriminative feature learning approach for deep face recognition. *Proceedings of the European Conference on Computer Vision (ECCV)*. 2016(1), 499-515.

- [24] Schroff, F., Kalenichenko, D., & Philbin, J. (2015). Facenet: A unified embedding for face recognition and clustering. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015(1), 815–823.
- [25] Deng, J., Guo, J., Xue, N., et al. (2022). ArcFace: Additive angular margin loss for deep face recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 44(10), 5962–5979.
- [26] Mollahosseini, A., Hasani, B., & Mahoor, M. H. (2017). Affectnet: A database for facial expression, valence, and arousal computing in the wild. *IEEE Transactions on Affective Computing*. 10(1), 18–31.
- [27] Li, S., Deng, W., & Du, J. (2019). Reliable crowdsourcing and deep locality-preserving learning for expression recognition in the wild. *IEEE Transactions on Image Processing*. 28(1), 356–370.
- [28] Zhang, K., Zhang, Z., Li, Z., et al. (2016). Joint face detection and alignment using multitask cascaded convolutional networks. *IEEE Signal Processing Letters*. 23(10), 1499–1503.
- [29] 章毓晋. 图像工程 (上册): 图像处理 [M]. 北京: 清华大学出版社, 2023: 85-98.
- [30] Zhang, H., Cisse, M., Dauphin, Y. N., et al. (2018). mixup: Beyond empirical risk minimization. *International Conference on Learning Representations (ICLR)*. 2018(1), 1–13.
- [31] Kim, J. H., Choo, W., & Song, H. O. (2020). Puzzle mix: Exploiting saliency and local statistics for optimal mixup. *International Conference on Machine Learning (ICML)*. 2020(1), 5275–5285.
- [32] 邱锡鹏. 神经网络与深度学习 [M]. 北京: 机械工业出版社, 2020: 109-130.
- [33] Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted boltzmann machines. *Proceedings of the International Conference on Machine Learning (ICML)*. 2010(1), 807–814.
- [34] Maas, A. L., Hannun, A. Y., & Ng, A. Y. (2013). Rectifier nonlinearities improve neural network acoustic models. *Proceedings of the International Conference on Machine Learning (ICML)*. 30(1), 3–8.
- [35] Hendrycks, D., & Gimpel, K. (2016). Gaussian error linear units (gelus). *arXiv preprint arXiv. 1606.8415*, 1–9.
- [36] Yu, F., & Koltun, V. (2016). Multi-scale context aggregation by dilated convolutions. *International Conference on Learning Representations (ICLR)*. 2016(1), 1–13.
- [37] Chen, L. C., Papandreou, G., Kokkinos, I., et al. (2018). DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 40(4), 834–848.
- [38] 王元, 李阳, 等. 基于区域注意力网络的遮挡人脸表情识别 [J]. 计算机学报, 2021, 44(5): 980-992.
- [39] Psaroudakis, A., & Kollias, D. (2022). MixAugment & Mixup: Augmentation methods for facial expression recognition. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022(1), 2367–2375.
- [40] Wang, K., Peng, X., Yang, J., et al. (2020). Suppressing uncertainties for large-scale facial expression recognition. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2020(1), 6897–6906.
- [41] Fard, A. P., & Mahoor, M. H. (2022). Ad-Corre: Adaptive correlation-based loss for facial expression recognition in the wild. *IEEE Access*. 10(1), 26756–26768.
- [42] El-Khashab, O., Hamdy, A., & Mahmoud, A. (2023). FerNeXt: Facial expression recognition using ConvNeXt with channel attention. *International Mobile, Intelligent, and Ubiquitous Computing Conference (MIUCC)*. 2023(1), 1–8.
- [43] Xue, F., Wang, Q., & Hu, G. (2021). TransFER: Learning relation-aware facial expression representations with transformers. *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2021(1), 3601–3610.
- [44] Minaee, S., Minaei, M., & Abdolrashidi, A. (2021). Deep-emotion: Facial expression recognition using attentional convolutional network. *Sensors*. 21(9), 3046–3059.
- [45] Goodfellow, I. J., Erhan, D., Luc, P., et al. (2013). Challenges in representation learning: A report on three machine learning contests. *International Conference on Neural Information Processing*. 2013(1), 117–124.
- [46] Pham, L., Vu, T. H., & Tran, T. A. (2021). Facial expression recognition using residual masking network. *International Conference on Pattern Recognition (ICPR)*. 2021(1), 4513–4519.